

## Lista Prática

### Question 1.

#### 1.1. FUNÇÕES DE VEROSSIMILHANÇA E ESTIMADORES

1) A mistura de normais é caracterizada da seguinte forma:

$$(1) \quad e_i \sim \begin{cases} N(\mu_1, \sigma_1^2), \text{ com probabilidade } 1/2, \\ N(\mu_2, \sigma_2^2), \text{ com probabilidade } 1/2. \end{cases}$$

Para computar a densidade, podemos modelar  $f(e_i) \sim \text{Bern}(1/2)$  e calcular  $\mathbb{E}_{\text{Bern}(1/2)} [f(e_i)]$ :

$$(2) \quad \mathbb{E}_{\text{Bern}(1/2)} [f(e_i)] = \frac{1}{2} \times \left[ \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{1}{2\sigma_1^2} (y_i - \beta_0 - \beta_1 x_i - \mu_1)^2\right) + \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{1}{2\sigma_2^2} (y_i - \beta_0 - \beta_1 x_i - \mu_2)^2\right) \right]$$

Podemos escrever a função de verossimilhança amostral como

$$(3) \quad \begin{aligned} L(\beta|\mathbf{y}, \mathbf{x}; \mu_1, \mu_2, \sigma_1^2, \sigma_2^2) &= \prod_{i=1}^n \frac{1}{2} \times \left[ \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{1}{2\sigma_1^2} (y_i - \beta_0 - \beta_1 x_i - \mu_1)^2\right) + \right. \\ &\quad \left. \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{1}{2\sigma_2^2} (y_i - \beta_0 - \beta_1 x_i - \mu_2)^2\right) \right] \\ &= \frac{1}{2^n} \prod_{i=1}^n \times \left[ \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{1}{2\sigma_1^2} (y_i - \beta_0 - \beta_1 x_i - \mu_1)^2\right) + \right. \\ &\quad \left. \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{1}{2\sigma_2^2} (y_i - \beta_0 - \beta_1 x_i - \mu_2)^2\right) \right]. \end{aligned}$$

Obtendo a log-verossimilhança:

$$(4) \quad \begin{aligned} l(\beta|\mathbf{y}, \mathbf{x}; \mu_1, \mu_2, \sigma_1^2, \sigma_2^2) &= -n \log(2) + \sum_{i=1}^n \log \left( \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{1}{2\sigma_1^2} (y_i - \beta_0 - \beta_1 x_i - \mu_1)^2\right) + \right. \\ &\quad \left. \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left(-\frac{1}{2\sigma_2^2} (y_i - \beta_0 - \beta_1 x_i - \mu_2)^2\right) \right). \end{aligned}$$

O Estimador de Máxima Verossimilhança é dado por

$$(5) \quad \hat{\beta} = \underset{\beta_0, \beta_1}{\operatorname{argmax}} l(\beta|\mathbf{y}, \mathbf{x}; \mu_1, \mu_2, \sigma_1^2, \sigma_2^2).$$

2) Função de verossimilhança amostral para  $u$ , com  $u_i \sim \Gamma(a, b)$ , definida para  $u_i > 0$ :

$$(6) \quad \begin{aligned} L(\beta|\mathbf{y}, \mathbf{x}; a, b) &= \prod_{i=1}^n \frac{b^a}{\Gamma(a)} (y_i - \beta_1 - \beta_2 x_i)^{a-1} \exp(-b(y_i - \beta_1 - \beta_2 x_i)) \\ &= \left( \frac{b^a}{\Gamma(a)} \right)^n \prod_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^{a-1} \exp\left(-b \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)\right). \end{aligned}$$

Aplicando transformação logarítmica

$$(7) \quad l(\beta|\mathbf{y}, \mathbf{x}; a, b) = n \log \left( \frac{b^a}{\Gamma(a)} \right) + (a-1) \sum_{i=1}^n \log(y_i - \beta_1 - \beta_2 x_i) - b \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i).$$

O Estimador de Máxima Verossimilhança é dado por

$$(8) \quad \hat{\beta} = \underset{\beta_0, \beta_1}{\operatorname{argmax}} l(\beta|\mathbf{y}, \mathbf{x}; a, b).$$

3) Sabemos que  $v_i \sim \text{Cauchy}(0, 1) \sim t(\nu = 1)$ , em que  $\nu$  representa os graus de liberdade. Portanto, a função de verossimilhança amostral para  $\mathbf{v}$ , com  $v_i \sim \text{Cauchy}(0, 1)$  pode ser escrita como:

$$(9) \quad \begin{aligned} L(\beta|\mathbf{y}, \mathbf{x}; \nu) &= \prod_{i=1}^n \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{(y_i - \beta_1 - \beta_2 x_i)^2}{\nu}\right) \\ &= \left[ \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \right]^n \prod_{i=1}^n \left(1 + \frac{(y_i - \beta_1 - \beta_2 x_i)^2}{\nu}\right). \end{aligned}$$

A log-verossimilhança, por sua vez,

$$(10) \quad l(\beta|\mathbf{y}, \mathbf{x}; \nu) = n \left[ \log \left( \Gamma\left(\frac{\nu+1}{2}\right) \right) - \log(\sqrt{\nu\pi}) - \log \left( \Gamma\left(\frac{\nu}{2}\right) \right) \right] + \sum_{i=1}^n \log \left( 1 + \frac{(y_i - \beta_1 - \beta_2 x_i)^2}{\nu} \right).$$

O Estimador de Máxima Verossimilhança é dado por

$$(11) \quad \hat{\beta} = \underset{\beta_0, \beta_1}{\operatorname{argmax}} l(\beta|\mathbf{y}, \mathbf{x}; \nu).$$

## 1.2. DISTRIBUIÇÕES ASSINTÓTICAS

Vide [1], Teorema 14.1.M2, *se são satisfeitas condições de regularidade*,

$$(12) \quad \hat{\theta} \xrightarrow{d} N(\theta_0, \{\mathbf{I}(\theta_0)\}^{-1}),$$

em que  $\hat{\theta}$  é o estimador de Máxima Verossimilhança de  $\theta_0$ , e  $\mathbf{I}(\theta_0) = -\mathbb{E} \left[ \frac{\partial^2 \log(L)}{\partial \theta_0 \partial \theta_0'} \right]$ .

### Condições de regularidade

blá blá blá

## REFERÊNCIAS

[1] WH Greene. Econometric analysis, 7th. saddle river, 2011.